ARCHITECTURE AGENTIQUE AUTONOME

Spécification Technique & Blueprint Systémique Multi-Boucles Local

MASTER BLUEPRINT V2.2 (INTÉGRAL)

Résumé Exécutif : Ce document régit l'installation globale du système IA autonome local. Il orchestre les modèles spécialisés (Qwen Coder 14B/32B, DeepSeek 32B, Mistral, Llama Vision, Flux/ComfyUI) via le harnais dsh, gère la mémoire persistante (Mem0 + AnythingLLM), connecte les sources de données (Google Drive Multi-Comptes, OneDrive, VS Code, n8n) et assure l'observabilité en temps réel avec un tableau de bord visuel animé (Langfuse + React Flow).

1. CARTOGRAPHIE DES 3 BOUCLES AGENTIQUES

Boucle Jaune — Mémoire

Rôle : Gestion de la mémoire et compression contextuelle.

- **Mem0 :** Extraction automatique de faits clés et préférences.
- **Gemma 2B / Llama 3B :** Agent ultra-léger de résumé.
- **AnythingLLM :** Vector DB & RAG documentaire local.

Boucle Orange — Exécution

Rôle : Exécution d'outils, Cloud & génération.

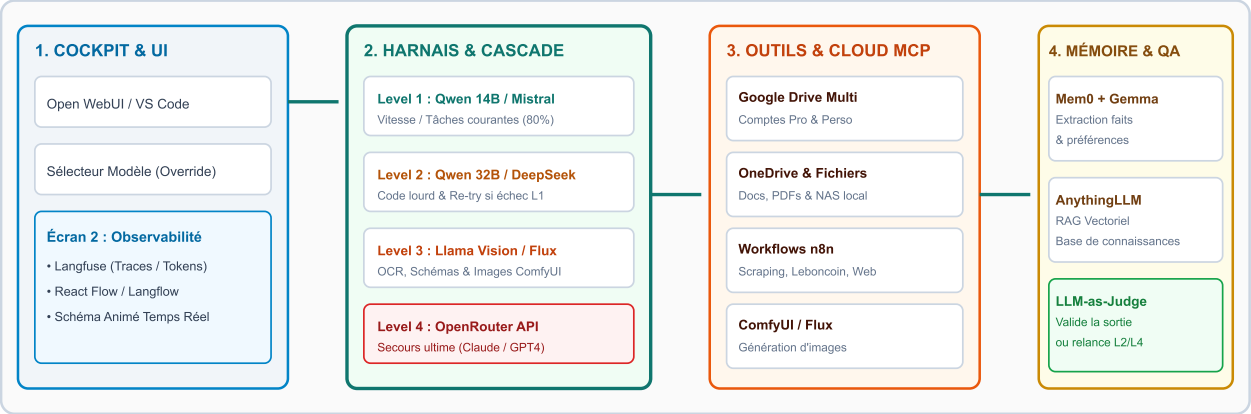
- **DeepSeek Harnais (dsh) :** Router & orchestrateur principal.
- **Serveurs MCP :** Google Drive Multi-comptes, OneDrive, Git.
- **Moteurs Outils :** Workflows n8n & ComfyUI (Images).

Boucle Verte — LLM Ops

Rôle : Auto-évaluation, qualité & observabilité.

- **LLM-as-a-Judge :** Validation déterministe des sorties.
- **Escalade automatique :** Re-try loop sur modèle supérieur.
- **Langfuse & React Flow :** Observabilité visuelle directe.

2. SCHÉMA SYSTÈME GLOBAL & FLUX D'EXÉCUTION



3. MATRICE EXHAUSTIVE DES MODÈLES IA DU SYSTÈME

Le système ne repose pas sur un modèle unique mais sur un **pool dynamique de modèles spécialisés**. Chaque modèle intervient selon son rapport vitesse/puissance et sa spécialité :

MODÈLE & TAILLE	HÉBERGEMENT	SPÉCIALITÉ & USAGE PRINCIPAL	NIVEAU DE CASCADE
Qwen 2.5 Coder 14B	Local (Ollama / vLLM)	Code rapide, scripts, formatage JSON, requêtes courantes.	NIVEAU 1 (Par défaut)
Mistral 7B / 12B	Local (Ollama)	Rédaction de contenus, synthèses de texte, emails, tri.	NIVEAU 1 (Généraliste)
Qwen 2.5 Coder 32B	Local (Ollama / vLLM)	Architecture logicielle, refactoring lourd, workflows n8n complexés.	NIVEAU 2 (Escalade Code)
DeepSeek 32B / R1	Local / OpenRouter	Raisonnement complexe, planification de tâches multi-étapes.	NIVEAU 2 (Planner / Agent)
Llama 3.2 Vision	Local (Ollama)	Lecture de documents scannés, OCR, analyse de schémas & graphiques.	NIVEAU 2 (Analyse Vision)
Flux / SD (ComfyUI)	Local (ComfyUI MCP)	Génération d'images pour catalogues, visuels web, rendus.	NIVEAU 2 (Génération Image)
Gemma 2B / Llama 3B	Local (Ollama)	Sous-agent d'arrière-plan pour la compression de mémoire Mem0.	INFRA (Boucle Jaune)
OpenRouter (Claude/GPT)	API Distante	Secours ultime en cas d'échec répété des modèles locaux.	NIVEAU 4 (Fallback Ultime)

4. LOGIQUE DE ROUTAGE EN CASCADE & CONTRÔLE UTILISATEUR

A. Routage Automatique par Escalade (Fallbacks)

Le harnais dsh applique un principe d'économie de ressources :

- **Démarrage ultra-rapide :** La tâche est d'abord confiée au modèle léger (ex: **Qwen 14B**).
- **Détection d'échec (Boucle Verte) :** Le composant *LLM-as-a-Judge* vérifie le résultat (syntaxe, critères respectés, format).
- **Escalade automatique :** En cas d'erreur ou de rejet, le harnais réinjecte le journal d'erreur et passe la tâche au modèle supérieur (**32B** ou **DeepSeek R1**).
- **Dernier recours :** Si le 32B échoue, bascule transparente vers l'API **OpenRouter**.

B. Sélection Manuelle (User Override)

L'utilisateur conserve la priorité absolue à tout moment :

- **Menu Déroulant UI :** Dans Open WebUI ou VS Code (Continue), un champ permet d'imposer un modèle spécifique pour une session.
- **Profils par Projet :** Possibilité de définir des règles strictes (ex: *"Projet X = 100% Qwen 14B pour préserver la VRAM GPU"*).
- **Déclenchement direct d'outils :** Dire *"Génère une image de..."* active automatiquement le MCP ComfyUI sans passer par l'escalade textuelle.

5. CONNECTEURS CLOUD & INTÉGRATION DOCUMENTAIRE

Connecteurs Google Drive (Multi-comptes) & OneDrive

Afin de permettre à l'agent de retrouver et d'analyser tous tes documents sans import manuel :

- **Google Drive MCP (Multi-comptes) :** Branchement simultané de tes comptes professionnels et personnels via l'API Google Workspace. L'agent peut rechercher des fichiers par nom, contenu, date ou dossier.
- **OneDrive MCP :** Connecteur Microsoft Graph permettant l'exploration des dossiers Cloud OneDrive, la lecture de tableurs Excel, et la synchronisation avec ton espace local.
- **RAG Hybride (AnythingLLM) :** Les documents importants identifiés sur le Cloud sont automatiquement indexés dans la base vectorielle locale pour des recherches sémantiques instantanées.

6. OBSERVABILITÉ VISUELLE EN TEMPS RÉEL (ÉCRAN SECONDARY DASHBOARD)

Pour sortir de l'effet "boîte noire", l'architecture intègre un **double système de suivi en direct** pour visualiser l'activation des boucles, la pensée des agents et le coût des requêtes :

A. Langfuse (Docker) - Traçabilité & Logs Fine

Plateforme d'observabilité open-source déployée en un clic via Docker Container.

- **Arbre d'exécution (Traces) :** Visualisation exacte de chaque appel de fonction et de chaque sous-agent.
- **Statistiques en direct :** Nombre de tokens consommés, modèle sollicité (14B vs 32B), latence en millisecondes.
- **Inspecteur MCP :** Visualisation des données brutes envoyées/reçues depuis Google Drive, n8n ou le système de fichiers.

B. Schéma Animé (React Flow / Langflow)

Interface visuelle interactive affichée en permanence sur un second écran.

- **Surbrillance Dynamique :** Chaque fois qu'une boucle s'active, la case correspondante sur le schéma s'allume (ex: Jaune quand Mem0 écrit, Orange quand n8n scripe).
- **Impulsions Lumineuses :** Des flux animés le long des flèches montrent le déplacement des données en temps réel.
- **Alerte d'Échec :** Clignotement rouge immédiat lors d'un rejet par la Boucle Verte suivi de l'animation d'escalade vers le modèle 32B.

7. SPÉCIFICATIONS TECHNIQUES DES COMPOSANTS CLÉS

DeepSeek Harnais (`dsh`) & Plugins Cordis

Moteur d'orchestration ultra-léger configuré pour piloter la cascade de modèles locaux et d'outils MCP.

- **Rôle :** Découpage du prompt utilisateur en plan d'action, choix du modèle adapté, et exécution des appels de fonctions JSON.
- **Interconnexion :** Émet des événements WebSocket en direct vers Langfuse et le Dashboard React Flow.

Mem0 + Gemma 2B (Moteur de Mémoire Persistante)

Évite la saturation du contexte lors des longues conversations ou recherches complexes.

- **Mécanisme :** Tous les 10 échanges, le sous-agent Gemma 2B extrait les faits durables (ex: *"L'utilisateur cherche un T3 à Nantes < 250k€"*) et les stocke dans la base sémantique.
- **Bénéfice :** L'agent se souvient de tes préférences d'un projet à l'autre sans surcharger le contexte du modèle principal.

Moteur de Workflows n8n & Serveurs MCP

Le bras armé du système pour les actions dans le monde réel.

- **Workflows n8n :** Automatismes complexes de scraping (Leboncoin, SeLoger), envoi de mails, gestion de factures.
- **Standard MCP :** Protocole unique permettant à l'agent de contrôler n8n, VS Code, Google Drive, OneDrive et ComfyUI avec la même facilité.

8. FEUILLE DE ROUTE D'INSTALLATION INTÉGRALE

ÉTAPE	COMPOSANT & ACTION	DÉTAILS D'EXÉCUTION & CONFIGURATION	STATUT
1.1	Configuration VS Code + MCP Host	Finalisation du serveur MCP local, validation des accès fichiers et du terminal.	TERMINÉ
1.2	Google Drive & OneDrive MCP	Authentification OAuth multi-comptes Google Drive et Microsoft Graph pour OneDrive.	EN COURS
2.1	Base RAG AnythingLLM & API	Configuration de la base vectorielle locale et exposition des clés API Developer.	À FAIRE
2.2	Mem0 + Gemma 2B (Memoire)	Installation du moteur Mem0 couplé à Ollama pour la compression contextuelle.	À FAIRE
3.1	DeepSeek Harnais & Cascade	Déploiement de dsh, règles de routage (Qwen 14B ➔ 32B ➔ OpenRouter) et menu UI.	À FAIRE
3.2	Bridge n8n & ComfyUI MCP	Exposition des Webhooks n8n et du serveur de génération d'images Flux/ComfyUI.	À FAIRE
3.3	Dashboard Animé & Langfuse	Lancement de Langfuse en Docker et configuration de l'interface React Flow sur écran 2.	À FAIRE
4.1	Boucle Verte & Registre Skills	Mise en place du validateur *LLM-as-a-Judge* et sauvegarde auto dans `SKILL.md`.	À FAIRE

9. EXEMPLE CONCRET D'EXÉCUTION : RECHERCHE IMMOBILIÈRE MULTI-CRITÈRES

Scénario : *"Trouve-moi la liste des appartements T3/T4 à vendre sur [Ville] < 250k€ avec terrasse, mets-les dans un tableau propre et fais une synthèse."*

1. **Réception Prompt :** Le harnais dsh attribue la tâche initiale à **Qwen 14B** (rapide).
2. **Appel Outil (Boucle Orange) :** Qwen 14B déclenche le workflow **n8n** de scraping des annonces et interroge **Google Drive / OneDrive** pour vérifier les fiches déjà sauvegardées.
3. **Traitement & Contrôle (Boucle Verte) :**
   - Si Qwen 14B génère le tableau parfait ➔ Validé par le Judge.
   - Si Qwen 14B rate un critère (ex: oubli du terrassement) ➔ Le Judge rejette le résultat, le harnais bascule automatiquement vers **Qwen 32B** qui corrige et finalise la réponse.
4. **Mémoire (Boucle Jaune) :** Mem0 extrait tes critères (T3/T4, Ville, < 250k€) pour s'en souvenir lors de tes prochaines sessions.
5. **Observabilité (Écran 2) :** Le schéma React Flow s'allume en direct à chaque étape et Langfuse enregistre le coût exact de la requête.

10. PRINCIPES DE MAINTENANCE & ÉVOLUTIVITÉ

- **Remplacement d'un Modèle :** Pour intégrer un nouveau modèle (ex: Qwen 3 ou Llama 4), il suffit de modifier son nom dans le fichier de config du harnais dsh. Aucun workflow n8n ou serveur MCP n'a besoin d'être réécrit.
- **Ajout de Comptes Cloud :** Il suffit de rajouter un jeton d'accès OAuth dans le serveur MCP Google Drive / OneDrive pour étendre instantanément le périmètre de recherche de l'agent.
- **Persistance de la Mémoire :** Les bases de données Mem0, AnythingLLM et les fichiers `SKILL.md` sont stockés en local sur le disque et survivent à toutes les mises à jour logicielles.