ARCHITECTURE AGENTIQUE AUTONOME

Spécification Technique & Spécification du Système Local Multi-Boucles

MASTER BLUEPRINT V2.0

Résumé Exécutif : Ce document est le schéma directeur de l'installation IA locale. Il définit le couplage entre les modèles spécialisés (Qwen Coder 32B, DeepSeek, Llama Vision), le chef d'orchestre (DeepSeek Harnais), la mémoire longue durée (Mem0 + AnythingLLM), les connecteurs opérationnels (MCP + n8n) et la boucle d'auto-évaluation.

1. CARTOGRAPHIE DES 3 BOUCLES AGENTIQUES

Boucle Jaune — Mémoire

Rôle : Gestion de la mémoire et compression de contexte.

- **Mem0 :** Extraction auto de faits persistants.
- **Gemma 2B / Llama 3.2 3B :** Sous-agent rapide de synthèse.
- **AnythingLLM :** Vector DB & RAG documentaire.

Boucle Orange — Exécution

Rôle : Pilotage des outils et orchestration des sous-tâches.

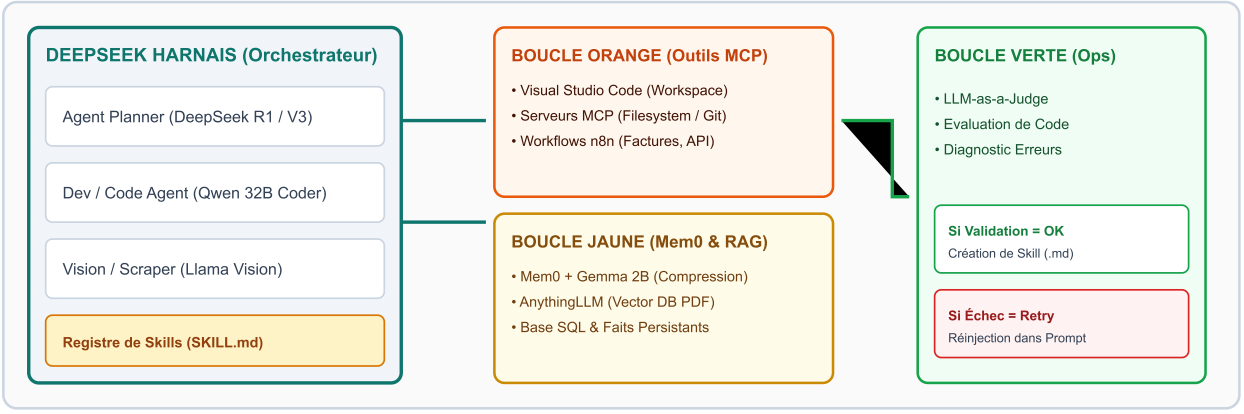
- **DeepSeek Harnais :** Chef d'orchestre principal.
- **Serveurs MCP :** Fichiers, Git, VS Code, Web.
- **n8n Workflows :** Exécuteur d'automatisations.

Boucle Verte — LLM Ops

Rôle : Auto-évaluation, correction et apprentissage.

- **LLM-as-a-Judge :** Validation des résultats.
- **Diagnostic Erreurs :** Auto-correction de code.
- **Registre SKILL.md :** Sauvegarde des acquis.

2. SCHÉMA FONCTIONNEL DU MÉTA-SYSTÈME



3. DÉCISIONS CLÉS D'ARCHITECTURE

- **Mem0 retenu face à Supermemory :** Mem0 est spécifiquement conçu pour l'extraction automatique de mémoire contextuelle au niveau du code de l'agent (support direct d'Ollama et de Qdrant/Chroma en local).
- **DeepSeek Harnais (`dsh`) retenu :** Choisi pour sa structure en plugins (Cordis) ultra-personnalisable permettant le routage dynamique vers Qwen 32B pour le code et OpenRouter pour les secours.
- **Standardisation MCP Universelle :** Le serveur MCP de Visual Studio Code devient la porte d'entrée globale pour interagir avec les fichiers, les dossiers du NAS et les scripts n8n.

4. MATRICE D'AFFECTATION DES MODÈLES IA

Afin de maximiser les performances et la vitesse tout en maîtrisant la consommation VRAM, chaque sous-tâche est déléguée au modèle le plus qualifié via un système de cascade dynamique (14B → 32B →